

Transcript de la sesión de IA — Actividad en clase, Sesión 3:

La ecuación salarial de tu estado (Nuevo León)

Gabriel Omar Pérez Hernández · A01736195 · CD2010

Conversación completa con el agente de IA en la terminal (Kimi Code), exportada sin ediciones como evidencia de uso de IA.

ID de sesión	session_2d357e4f-0cb4-4325-98ac-8d2c40c53857
Exportada	2026-08-19T22:24:58.721Z
Directorio de trabajo	/Users/gabrielomarperezhernandez
Mensajes	65
Tokens	45231

Kimi Session Export

Overview

- **Topic:** cd ~/Desktop/“Carpeta Local Clase”
- **Conversation:** 8 turns | 23 tool calls

Turn 1

User

cd ~/Desktop/“Carpeta Local Clase”

Assistant

Thinking

The user typed a cd command. I should switch working directory context — but Bash calls don’t persist cwd. Best: just note it and list the directory, or run with cwd. I’ll treat it as “work in that directory” and show contents.

Tool Call: Bash (ls -la "/Users/gabrielomarperezhernandez/Desktop/Carpeta Loc...)

```
{
  "command": "ls -la \"/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase\""
}
```

Tool Result: Bash (ls -la "/Users/gabrielomarperezhernandez/Desktop/Carpeta Loc...)

total 864432 drwxr-xr-x@ 19 gabrielomarperezhernandez staff 608 16 ago 23:32 . drwx——@ 12 gabrielomarperezhernandez staff 384 16 ago 23:33 .. -rw-r-r-@ 1 gabrielomarperezhernandez staff 12292 14 ago 15:45 .DS_Store drwxr-xr-x@ 12 gabrielomarperezhernandez staff 384 12 ago 16:55 .git -rw-r-r-@ 1 gabrielomarperezhernandez staff 0 12 ago 15:57 1 -rw-r-r-@ 1 gabrielomarperezhernandez staff 117242 13 ago 16:47 A01736195_Nuevo Leon_transcript.md -rw-r-r-@ 1 gabrielomarperezhernandez staff 673 13 ago 17:28 ActividadNacimientos.ipynb -rw-r-r-@ 1 gabrielomarperezhernandez staff 117242 13 ago 16:47 Copia de A01736195_Nuevo Leon_transcript.txt -rw-r-r- 1 gabrielomarperezhernandez staff 40843186 13 ago 16:06 enoe_2026_trim1_csv.zip -rw-rw-rw- 1 gabrielomarperezhernandez staff 143776056 23 abr 16:23 ENOE_COE1T126.csv -rw-rw-rw- 1 gabrielomarperezhernandez staff 107411589 23 abr 16:23 ENOE_COE2T126.csv drwx——@ 5 gabrielomarperezhernandez staff 160 13 ago 15:47 enoe_english_00_csv -rw-rw-rw- 1 gabrielomarperezhernandez staff 17649374 23 abr 16:26 ENOE_HOGT126.csv -rw-rw-rw- 1 gabrielomarperezhernandez staff 119086134 23 abr 16:23 ENOE_SDEMT126.csv -rw-rw-rw- 1 gabrielomarperezhernandez staff 13393671 23 abr 16:22 ENOE_VIVT126.csv drwxr-xr-x@ 8 gabrielomarperezhernandez staff 256 16 ago 23:32 Extracci-n-de-datos -rw-r-r-@ 1 gabrielomarperezhernandez staff 58306 13 ago 16:42 ingreso_por_escolaridad_NL.png -rw-r-r-@ 1 gabrielomarperezhernandez staff 95916 12 ago 17:42 MuestraNacimientos23Sucio.csv -rw-r-r-@ 1 gabrielomarperezhernandez staff 902 13 ago 17:28 Prueba Visual.ipynb

Thinking

User just cd'd. I'll use this as the working directory context going forward. Respond briefly in Spanish.

Listo, estamos en ~/Desktop/Carpeta Local Clase. Contenido:

- **Datos ENOE:** ENOE_COE1T126.csv, ENOE_COE2T126.csv, ENOE_HOGT126.csv, ENOE_SDEMT126.csv, ENOE_VIVT126.csv y enoe_2026_trim1_csv.zip
- **Notebooks:** ActividadNacimientos.ipynb, Prueba Visual.ipynb
- **Otros:** A01736195_Nuevo Leon_transcript.md, MuestraNacimientos23Sucio.csv, ingreso_por_escolaridad_NL.png, carpeta Extracci-n-de-datos/

Es un repositorio git. ¿Qué necesitas hacer aquí?

Turn 2

User

Vamos a construir modelos de regresion con los datos de la ENOE de mi estado, Nuevo Leon (cve_ent = 19), usando el archivo ENOE_SDEMT126.csv que esta en esta carpeta. Restringe la muestra a personas ocupadas (clase1 == 1) con ingreso por hora positivo (ing_x_hrs > 0), y dime exactamente que restricciones aplicaste y cuantas observaciones sobrevivieron. De ahora en adelante, cada vez que me reportes un resultado, muéstrame tambien el codigo o la logica con que lo obtuviste.

Assistant

Thinking

The user wants regression models with ENOE data for Nuevo León (cve_ent=19), from ENOE_SDEMT126.csv. First step: restrict sample to clase1==1 and ing_x_hrs>0, report restrictions and surviving observations, and always show code/logic.

Let me check Python environment and columns. The file is 119MB. Let me run a quick exploration with pandas.

Voy a revisar el archivo y aplicar las restricciones con Python. Primero verifico el entorno y las columnas.

Tool Call: Bash (which python3 && python3 -c "import pandas; print(pandas.__v...)

```
{
  "command": "which python3 && python3 -c \"import pandas; print(pandas.__version__)\""
}
```

Tool Result: Bash (which python3 && python3 -c "import pandas; print(pandas.__v...)

Tool "Bash" was not run because the user rejected the approval request.

Thinking

The user rejected. Maybe they want me to just proceed differently, or the approval was rejected accidentally. I should ask, or try again? Guidance says don't retry unchanged. Ask user how they'd prefer. Actually maybe the rejection was accidental. I'll ask briefly.

El comando fue rechazado. ¿Cómo prefieres que lo corra?

- Puedo usar python3 con pandas desde la terminal (lo típico).
- O si prefieres trabajar en un notebook (como tus .ipynb de la carpeta), puedo crear uno y ejecutarlo ahí.

Dime cuál opción y sigo con el filtrado de la muestra.

Turn 3

User

Fue un error de dedo. Mi respuesta era la 2, continua sin restricciones

Assistant

Thinking

User wants option 2: work in a notebook. “Continúa sin restricciones” — proceed. Create a notebook in the folder and execute it. I’ll need jupyter/nbconvert to execute. Let me check availability first, then build a notebook that loads the CSV, filters, reports counts.

Entendido, trabajo en notebook. Verifico las herramientas disponibles.

Tool Call: Bash (which python3; python3 -c "import pandas; print('pandas', pa...)

```
{
    "command": "which python3; python3 -c \"import pandas; print('pandas', pandas.__version__)\"; python3 -c \"import jupyter; print('jupyter ok')\" 2>/dev/null; python3 -m jupyter --version 2>/dev/null | head -5; python3 -c \"import nbformat, nbclient; print('nbformat+nbclient ok')\""
}
```

Tool Result: Bash (which python3; python3 -c "import pandas; print('pandas', pa...)

```
/Library/Frameworks/Python.framework/Versions/3.14/bin/python3 pandas 3.0.5 jupyter ok Selected Jupyter core packages... IPython : 9.16.1 ipykernel : 7.3.0 ipywidgets : not installed jupyter_client : 8.9.1 Traceback (most recent call last): File "", line 1, in import nbformat, nbclient; print('nbformat+nbclient ok') ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^ ModuleNotFoundError: No module named 'nbformat' Command failed with exit code: 1.
```

Thinking

pandas available, ipykernel available, but no nbformat/nbclient. I can still create a notebook (JSON) and execute it via jupyter kernel... Without nbclient I can use `jupyter execute`? There's `jupyter execute` from `jupyter_client`? Actually `jupyter execute` exists in newer `jupyter_client` (`jupyter_client` $\geq$ 8 has `jupyter execute`? No — IPython has... Actually, `jupyter execute` was added in `nbclient`? Let me think: `nbclient` provides `jupyter-execute` CLI. Without it, options:

1. Install nbformat+nbclient in a venv — but pandas is in system python; a venv would need pandas too.
2. Write notebook JSON manually and execute via a small script using jupyter_client directly to run cells through a kernel.
3. pip install --user nbformat nbclient (outside working dir — needs confirmation? It's user site-packages; mild. Guidelines say avoid installing outside working dir; pip --user installs to ~/Library. Better ask or use isolated venv.)

Simplest robust: create venv in the project folder with `--system-site-packages` so pandas is available, then pip install nbformat nbclient into the venv. That's isolated inside working dir.

Actually even simpler: write a script using `jupyter_client`'s blocking kernel client to execute code and capture outputs, then build the `.ipynb` JSON manually with outputs. That avoids installs but is more code. The `venv` approach is cleaner.

Let me do: `python3 -m venv .venv --system-site-packages` in the class folder, then `.venv/bin/pip install nbformat nbclient`.

Then create notebook “Modelos_ENOE_NL.ipynb” with a first cell loading data and filtering, execute with jupyter nbconvert? nbconvert not installed either; use nbclient directly via python -m nbclient? There’s python -m nbclient no... nbclient has CLI jupyter execute provided by nbclient package (entry point jupyter-execute). Yes, nbclient installs a jupyter-execute script.

I'll write a small runner script that uses nbclient API to execute the notebook in place. That's reliable.

Plan: 1. Create venv with system site packages. 2. Install nbformat nbclient. 3. Write notebook (nbformat) with cell: load ENOE_SDEMT126.csv selected columns? First need to know columns exist: cve_ent, clase1, ing_x_hrs. ENOE SDEM has these. I'll write the cell defensively.

The CSV is 119MB, latin-1 encoding likely. Load with encoding='latin-1'. Filtering: cve_ent==19, clase1==1, ing_x_hrs>0. Report counts at each step.

Let me create the venv and install (background maybe). pip install of nbformat+nbclient is small.

Tool Call: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

```
{
  "command": "cd \\\"/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase\\\" && python3 -m venv .venv --system-site-packages && .venv/bin/pip install -q nbformat nbclient && .venv/bin/python -c \\\"import nbformat, nbclient, pandas; print('ok')\\\"",
  "timeout": 180
}
```

Tool Result: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

ok

Thinking

Now create the notebook. First cell: inspect columns to confirm names (cheap: read header only). Second cell: load full file with only needed columns? For regressions later we'll need more variables, but for now load relevant subset. Better: load the full file? 119MB is fine for pandas but slow-ish; load with usecols once we know columns. For the filtering task, I need cve_ent, clase1, ing_x_hrs. But later regressions will need more (edad, escolaridad, sexo, hrsocup, etc.). I could load a broader set of typical columns. Keep simple: first notebook cell reads header and shows columns; then filtering cell loads usecols=[cve_ent, clase1, ing_x_hrs] — later cells can reload with more columns. Actually reloading a 119MB file repeatedly is wasteful but fine.

Better plan: load a curated set of columns useful for wage regressions in one go: cve_ent, clase1, ing_x_hrs, sexo, eda, anios_esc, hrsocup, and maybe others. But I'm not 100% sure of column names in this file (ENOE SDEM T126). Names: SDEM has 'sex', 'eda', 'anios_esc', 'hrsocup', 'ing_x_hrs', 'clase1', 'cve_ent'. Also 'ent' vs 'cve_ent'. Let me first peek at the header quickly via bash head -1 before writing the notebook.

Ahora reviso el encabezado del CSV para confirmar los nombres de columnas.

Tool Call: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

```
{
  "command": "cd \"/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase\" && head -c 4000 ENOE_SDEMT126.csv | head -2 | cut -c1-2000"
}
```

Tool Result: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

r_def,cve_loc,cve_mun,est,est_d_tri,est_d_men,cve_ageb,t_loc_tri,t_loc_men,cd_a,cve_ent,con,upm,d_sem,n_pro_viv,v_sel,n_hog,h_mud,n_ent,per,n_ren,c
0, ,007,30,671,671,00000,1,1,1,09,40006,906681,307,117,5,1,0,2,126,1,1,101,2,61,7,4,1964,9,1,4,2, , , ,2,2,3,1,9,1,7, , , , , , ,
,1,2,9582,504,1726,1,1,1,1,1,4,8,2,7,6,3,4,3,9,5,2,5,2,3,0,2,0,0,0,0,1,1,3,0,0,0,0,3,3,6,10,15,2,3,11,50,10000,46.51163,0,3,0,1,0,2,16,1,2,2,0,3,2,6,2,2,09007

Thinking

Columns confirmed: cve_ent, clase1, ing_x_hrs, plus sexo, eda, anios_esc, hrsocup, fac_tri, ingocup, pos_ocu, rama, etc. Note: cve_ent appears as '09' with leading zero? Row shows ...cd_a=1, cve_ent='09'... values are quoted-ish with leading zeros and blanks as ' '. cve_ent may be string like '19'. Also eda shows '2'? Wait: after per=126... let me not over-parse; handle in pandas by reading cve_ent as string and comparing after strip, or read as Int64. Actually values like '09' with leading zero — pandas will parse as int 9 if read normally? The CSV has spaces (' ') for missing. Reading with default dtype, cve_ent '09' → parses as string? Mixed... Safer: dtype=str then strip and convert.

Now build the notebook with nbformat and execute with nbclient. Notebook cells:

1. Markdown: title + description of task.
2. Code: imports, load CSV with dtype=str? That makes everything string; converting needed cols to numeric. Load usecols of interest to keep memory lower: ['cve_ent','clase1','ing_x_hrs','sexo','eda','anios_esc','hrsocup','ingocup','fac_tri'] with dtype=str, then to numeric. Encoding: try utf-8 first? INEGI files usually latin-1, but header parsed fine. Values are numeric mostly; encoding matters little. Use encoding='latin-1' to be safe.

Cell reports: - total rows in file - after cve_ent==19 - after clase1==1 - after ing_x_hrs>0 with counts and % retained, printed clearly.

Then report to user with code.

Write a Python script to create+execute notebook in place. Kernel: python3 (ipykernel installed system-wide). nbclient will use 'python3' kernel.

Notebook name: 'Modelos_ENOE_NL.ipynb'.

EDA value check: 'eda' may contain spaces. Fine.

Let me write the runner script.

Tool Call: Write (/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase...)

```
{
  "path": "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/ejecutar_nb.py",
  "content": "\"\"\"Ejecuta Modelos_ENOE_NL.ipynb en su lugar (in place) con nbclient.\"\"\"\n\nimport sys\nimport nbformat\nfrom nbclient import NotebookClient\n\nruta = \"/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/Modelos_ENOE_NL.ipynb\"\nnb = nbformat.read(ruta, as_version=4)\ncliente = NotebookClient(nb, timeout=600,
```


Tool Result: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

Notebook creado [IPKernelApp] WARNING | Kernel is running over TCP without encryption. All communication (including code and outputs) is sent in plain text and is susceptible to eavesdropping. Use IPC transport or launch with kernel manager-provisioned CurveZMQ keys to enable transport encryption. Notebook ejecutado y guardado: /Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/Modelos_ENOE_NL.ipynb

Thinking

Notebook executed. Now read outputs from the notebook to report results. The task is short; todo list not really needed. Just read the notebook outputs.

Extraigo las salidas del notebook para reportarte los números.

Tool Call: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

```
{
  "command": "cd \"/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase\" &&
.venv/bin/python - <<'EOF'\nimport nbformat, json\nnb =
nbformat.read(\"Modelos_ENOE_NL.ipynb\", as_version=4)\nfor i, cel in enumerate(nb.cells):\n
if cel.cell_type != \"code\":\n    continue\n    print(f\"==== Celda {i} ====\")\n
for sal in cel.get(\"outputs\", []):\n    if sal.output_type == \"stream\":\n
print(sal.text)\n    elif sal.output_type in (\"execute_result\", \"display_data\"):\n
txt = sal.get(\"data\", {}).get(\"text/plain\", \"\")\n    print(txt)\n    elif
sal.output_type == \"error\":\n    print(\"ERROR:\", sal.ename, sal.evalue)\nEOF"
}
```

Tool Result: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

==== Celda 1 ==== Observaciones totales en el archivo: 417,437

==== Celda 2 ==== Archivo completo (nacional) n = 417,437 (100.00% del total) + cve_ent == 19 (Nuevo León) n = 13,013 (3.12% del total) + clase1 == 1 (ocupados) n = 6,074 (1.46% del total) + ing_x_hrs > 0 (ingreso/hora positivo) n = 3,582 (0.86% del total)

Muestra final: 3,582 observaciones

==== Celda 3 ==== ing_x_hrs eda anios_esc hrsocup count 3582.00 3582.00 3582.00 3582.00 mean 89.06 39.21 11.04 42.06 std 97.09 13.94 6.31 15.87 min 0.40 12.00 0.00 1.00 25% 48.36 28.00 9.00 36.00 50% 64.60 38.00 10.00 45.00 75% 100.00 50.00 12.00 48.00 max 3000.00 98.00 99.00 108.00

Thinking

Report results with code/logic shown, as user requested.

Listo. El notebook Modelos_ENOE_NL.ipynb quedó creado y ejecutado en la carpeta.

Restricciones aplicadas (en este orden)

- 1. cve_ent == 19 — solo registros de Nuevo León
- 2. clase1 == 1 — solo personas ocupadas
- 3. ing_x_hrs > 0 — solo ingreso por hora positivo

Observaciones que sobrevivieron

Paso	n	% del total
Archivo completo (nacional)	417,437	100%
+ Nuevo León	13,013	3.12%
+ ocupados	6,074	1.46%
+ ingreso/hora > 0	3,582	0.86%

Muestra final: 3,582 observaciones.

Código con que lo obtuve

```
cols = ['cve_ent', 'clase1', 'ing_x_hrs',
        'sex', 'eda', 'anios_esc', 'hrsocup', 'ingocup', 'fac_tri']

# Se lee como texto porque el archivo usa espacios (' ') como faltantes
# y ceros a la izquierda en algunas claves; luego se convierte a numérico.
df = pd.read_csv('ENOE_SDEMT126.csv', usecols=cols, dtype=str, encoding='latin-1')
for c in cols:
    df[c] = pd.to_numeric(df[c].str.strip(), errors='coerce')

m1 = df['cve_ent'] == 19
m2 = df['clase1'] == 1
m3 = df['ing_x_hrs'] > 0
muestra = df[m1 & m2 & m3].copy()
```

Con assert verifiqué que ningún caso de la muestra final viola las tres condiciones. Estadísticos rápidos de la muestra: ingreso/hora mediana de \$64.60 (media \$89.06), edad mediana 38 años, mediana de 10 años de escolaridad y 45 horas trabajadas a la semana.

¿Qué modelo quieres primero? Lo natural sería una regresión de Mincer: $\log(\text{ing_x_hrs})$ sobre anios_esc , eda y eda^2 , y de ahí agregar sexo u otras variables.

Turn 4

User

Con esa misma muestra, corre una regresión simple por mínimos cuadrados ordinarios: variable dependiente = ing_x_hrs , única variable explicativa = anios_esc . Sin logaritmos, la quiero en niveles para interpretar la pendiente en pesos por hora. Muéstrame el código, la tabla de coeficientes con errores estándar y p-values, y el R-cuadrado.

Assistant

Thinking

Add a cell to the notebook: OLS $\text{ing_x_hrs} \sim \text{anios_esc}$ with statsmodels. Check statsmodels availability first, then append cell and re-execute notebook.

Agrego la regresión al notebook. Verifico que statsmodels esté disponible.

Tool Call: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

```
{
  "command": "cd \"/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase\" &&
  .venv/bin/python -c \"import statsmodels; print(statsmodels.__version__)\"
}
```

Tool Result: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

Traceback (most recent call last): File "", line 1, in import statsmodels; print(statsmodels.__version__) ~~~~~~
ModuleNotFoundError: No module named 'statsmodels' Command failed with exit code: 1.

Tool Call: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

```
{
  "command": "cd \"/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase\" &&
  .venv/bin/pip install -q statsmodels && .venv/bin/python -c \"import statsmodels;
  print('statsmodels', statsmodels.__version__)\"",
  "timeout": 180
}
```

```
Tool Result: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...
statsmodels 0.14.6
```

Tool Call: Write (/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase...)

```
{
    "content": "import nbformat\nruta = '/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/Modelos_ENOE_NL.ipynb'\nnnb = nbformat.read(ruta,\nas_version=4)\nnnb.cells.append(nbformat.v4.new_markdown_cell(\n        \"## Regresión 1: MCO simple en niveles\\n\\n\" \n        \"$ing\\\\x\\\\hrs_i = \\\\beta_0 + \\\\beta_1 \\\\cdot años\\\\esc_i + u_i$\" \n        \"La pendiente $\\\\beta_1$ se interpreta como pesos por hora adicionales \\npor cada año extra de escolaridad.\"))\nnnb.cells.append(nbformat.v4.new_code_cell(\n        \"import statsmodels.api as sm\\n\\n\" \n        \"# Variables del modelo (la muestra ya está filtrada)\\n\\n\" \n        \"datos_m1 = muestra[['ing_x_hrs', 'años_esc']].dropna()\\n\\n\" \n        \"print(f'Observaciones usadas en la regresión: {len(datos_m1)},')\" \n        f'(se descartan {len(muestra) - len(datos_m1)} con años_esc faltante)' )\\n\\n\" \n        \"y = datos_m1['ing_x_hrs']\\nX = sm.add_constant(datos_m1['años_esc'])\\n\\n\" \n        \"modelo1 = sm.OLS(y, X).fit()\\n\\n\" \n        \"print(modelo1.summary())\")\nnnbformat.write(nnb, ruta)\nprint(\"Celda agregada\")\n\",
    "path": "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/agregar_reg1.py"
```

Tool Result: Write (/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase...)

Wrote 1062 bytes to /Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/agregar_reg1.py

Tool Call: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

```
{
    "command": "cd \"/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase\" &&
.venv/bin/python  agregar_reg1.py  && .venv/bin/python  ejecutar_nb.py  2>/dev/null &&
.venv/bin/python  -  <<'EOF'\nimport nbformat\nnb = nbformat.read(\"Modelos_ENOE_NL.ipynb\",
as_version=4)\ncel = nb.cells[-1]\nfor sal in cel.get(\"outputs\", []):\n    if
sal.output_type == \"stream\":\n        print(sal.text)\n    elif sal.output_type ==
\"error\":\n        print(\"ERROR:\", sal.ename, sal.evalue)\nEOF",
    "timeout": 300
}
```

Tool Result: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

Celda agregada Notebook ejecutado y guardado: /Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/Modelos_ENOE_NL.ipynb Observaciones usadas en la regresión: 3,582 (se descartan 0 con anios_esc faltante) OLS Regression Results

===== Dep. Variable: ing_x_hrs R-squared: 0.017 Model: OLS Adj. R-squared: 0.016 Method: Least Squares F-statistic: 60.31 Date: Mon, 17 Aug 2026 Prob (F-statistic): 1.05e-14 Time: 16:46:17 Log-Likelihood: -21442. No. Observations: 3582 AIC: 4.289e+04 Df Residuals: 3580 BIC: 4.290e+04 Df Model: 1 Covariance Type: nonrobust

===== coef std err t P> t [0.025									
0.975]	----- const 67.2034 3.241 20.733 0.000 60.848 73.559 anios_esc 1.9795								
0.255	7.766	0.000	1.480	2.479					

===== Omnibus: 6119.076 Durbin-Watson: 1.844 Prob(Omnibus): 0.000 Jarque-Bera (JB): 11005418.977 Skew: 11.332 Prob(JB): 0.00 Kurtosis: 273.600 Cond. No. 25.7
=====

Notes: [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Thinking

Report with code, coefficients, SE, p-values, R².

Regresión corrida y guardada en el notebook. Resultados:

Tabla de coeficientes (n = 3,582; no hubo faltantes en anios_esc)

Coeficiente	Estimación	Error estándar	t	p-value	IC 95%
Intercepto (const)	67.20	3.24	20.73	<0.001	[60.85, 73.56]
anios_esc	1.98	0.25	7.77	<0.001	[1.48, 2.48]

$R^2 = 0.017$ (R^2 ajustada = 0.016). $F(1, 3580) = 60.31$, $p \approx 1.05e-14$.

Interpretación

Cada año adicional de escolaridad se asocia con **~1.98 pesos/hora más** de ingreso, estadísticamente significativo. El intercepto (67.20) es el ingreso/hora predicho para alguien con 0 años de escolaridad. La R^2 de 1.7% indica que la escolaridad sola explica muy poco de la variación del ingreso por hora — normal en secciones cruzadas sin más controles.

Código

```
import statsmodels.api as sm

datos_m1 = muestra[['ing_x_hrs', 'anios_esc']].dropna()
y = datos_m1['ing_x_hrs']
X = sm.add_constant(datos_m1['anios_esc'])

modelo1 = sm.OLS(y, X).fit()
print(modelo1.summary())
```

Nota técnica: los errores estándar son los clásicos (no robustos). Dado que la distribución del ingreso por hora es muy asimétrica (asimetría de 11.3 y máximo de \$3,000/hr), convendría en algún momento usar errores robustos a heteroscedasticidad (`fit(cov_type='HC1')`) — solo cambia la inferencia, no los coeficientes. ¿Lo agregamos, o seguimos con una regresión múltiple (edad, edad², sexo)?

Turn 5

User

Sigamos con la regresión múltiple, misma muestra y misma dependiente (`ing_x_hrs` en niveles). Agrega estas tres variables explicativas junto a `anios_esc`: (1) experiencia potencial = `eda - anios_esc - 6`, (2) una dummy mujer que valga 1 si `sex == 2` y 0 si es hombre, y (3) `hrsocup` (horas trabajadas a la semana). Muéstrame el código, la tabla completa de coeficientes con errores estándar y p-values, y la R-cuadrada. Y avísame si alguna variable tiene valores raros, por ejemplo experiencia negativa, y cuantos casos son.

Assistant

Thinking

Add cells: create `exper = eda - anios_esc - 6`, `mujer = (sex==2)`, check weird values (`exper<0` count, `anios_esc==99` is “no sabe” — max was 99! That’s a red flag: `anios_esc=99` likely “no especificado”. Also `eda` max 98 could be valid. Should flag `anios_esc=99`. The user asked to warn about weird values, e.g. negative experience, and how many. I should check: `anios_esc==99` cases, `exper<0` cases. Per instructions “avisame” — report but still run regression as specified? Running with `anios_esc=99` included would distort. The user asked to be warned; I’ll run as specified but flag the 99 issue and how many. Actually running with 99s included gives a misleading coefficient. Best: run the requested regression as-is, and additionally report diagnostics; maybe also show the regression without `anios_esc==99` as sensitivity? User said “avisame si alguna variable tiene valores raros y cuantos casos son” — so main job: run regression, warn. I could run the main spec as requested and note the issue, offering to refit. Keep simple: run as requested, flag issues, and optionally show refit excluding the weird cases as comparison. I’ll include a quick sensitivity refit excluding `anios_esc==99` and `exper<0`? That may be overreach... but it’s genuinely useful and cheap. The guideline: don’t give more than what they want. I’ll run the requested model, flag anomalies with counts, and mention

I can refit excluding them. Hmm, but negative experience values are a genuine data-quality matter the user explicitly asked to be warned about — refitting is a natural follow-up question. Keep to requested model + warnings.

Agrego la regresión múltiple al notebook, con revisión de valores raros.

Tool Call: Write (/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase...)

[illegible]

Tool Result: Write (/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase...) Wrote 2174 bytes to /Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/agregar_reg2.py

Wrote 2174 bytes to /Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/agregar_reg2.py

Tool Call: Bash (cd "/Users/gabrielomarperzhernandez/Desktop/Carpeta Local C...)

```
{
    "command": "cd \"/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase\" &&
.venv/bin/python  agregar_reg2.py  && .venv/bin/python  ejecutar_nb.py  2>/dev/null  &&
.venv/bin/python  - <<'EOF'\nimport nbformat\nnb = nbformat.read(\"Modelos_ENOE_NL.ipynb\",
as_version=4)\nfor cel in nb.cells[-2:]:\n            if cel.cell_type != \"code\":\ncontinue\n        for sal in cel.get(\"outputs\", []):\n            if sal.output_type ==
\"stream\":\n                print(sal.text)\n            elif sal.output_type == \"error\":\nprint(\"ERROR:\", sal.ename, sal.evalue)\nEOF",
    "timeout": 300
}
```

Tool Result: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

```
Celdas      agregadas      Notebook      ejecutado      y      guardado:      /Users/gabrielomarperezhernandez/Desktop/Carpeta      Local
Clase/Modelos_ENOE_NL.ipynb Valores raros detectados: anios_esc == 99 (código de 'no especificado'): 12 casos exper < 0 (experiencia
potencial negativa): 36 casos eda > 97 (tope/código especial): 1 casos hrsocup > 84 (más de 12h x 7 días): 29 casos
```

Celdas agregadas Notebook ejecutado y guardado: /Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/Modelos_ENOE_NL.ipynb Valores raros detectados: años_esc == 99 (código de 'no especificado'): 12 casos exper < 0 (experiencia potencial negativa); 36 casos eda > 97 (tope/código especial); 1 casos hrsocup > 84 (más de 12h x 7 días); 29 casos

Rango de exper: [-76.0, 83.0] Rango de anios_esc: [0, 99] Distribución de mujer: {0: 2151, 1: 1431}

Observaciones usadas en la regresión: 3,582 OLS Regression Results

===== Dep. Variable: ing_x_hrs R-squared: 0.107 Model: OLS Adj. R-squared: 0.106 Method: Least Squares F-statistic: 107.3 Date: Mon, 17 Aug 2026 Prob (F-statistic): 2.00e-86 Time: 17:54:11 Log-Likelihood: -21269. No. Observations: 3582 AIC: 4.255e+04 Df Residuals: 3577 BIC: 4.258e+04 Df Model: 4 Covariance Type: nonrobust

===== coef std err t P>|t| [0.025 0.975] ----- const 142.4843 7.036 20.250 0.000 128.689 156.280 anios_esc 2.3997 0.283 8.477 0.000 1.845 2.955 exper 0.2434 0.111 2.185 0.029 0.025 0.462 mujer -20.9263 3.200 -6.539 0.000 -27.201 -14.652 hrsocup -1.8295 0.099 -18.482 0.000 -2.024 -1.635

===== Omnibus: 6212.457 Durbin-Watson: 1.868 Prob(Omnibus): 0.000 Jarque-Bera (JB): 12699895.478 Skew: 11.664 Prob(JB): 0.00 Kurtosis: 293.770 Cond. No. 237. =====

Notes: [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Thinking

Report. Flag weird values: 12 casos anios_esc==99 (no especificado), 36 exper<0, 29 hrsocup>84, 1 eda>97. Recommend refit excluding the 12 + 36. Offer next step.

Regresión múltiple estimada y guardada en el notebook. n = 3,582 (sin faltantes nuevos).

Tabla de coeficientes

Variable	Coef.	Error est.	t	p-value	IC 95%
Intercepto	142.48	7.04	20.25	<0.001	[128.69, 156.28]
anios_esc	2.40	0.28	8.48	<0.001	[1.85, 2.96]
exper	0.24	0.11	2.19	0.029	[0.03, 0.46]
mujer	-20.93	3.20	-6.54	<0.001	[-27.20, -14.65]
hrsocup	-1.83	0.10	-18.48	<0.001	[-2.02, -1.64]

$R^2 = 0.107$ (ajustada = 0.106) — sube de 0.017 a 0.107 respecto a la regresión simple.

Interpretación rápida: un año más de escolaridad → +\$2.40/hr; un año más de experiencia → +\$0.24/hr; ser mujer se asocia con -\$20.93/hr respecto a hombres (brecha cruda); cada hora semanal adicional trabajada se asocia con -\$1.83 en el ingreso *por hora* (trabajos de más horas tienden a pagar menos por hora).

! Valores raros detectados

Problema	Casos
anios_esc == 99 (código ENOE de “no especificado”, no son 99 años reales)	12
exper < 0 (experiencia potencial negativa; típicamente en edad o escolaridad inconsistente)	36
hrsocup > 84 (más de 12 h × 7 días; plausible pero extremo, máx. 108)	29
eda > 97 (tope de codificación)	1

Los 12 de anios_esc == 99 son los más preocupantes: inflan artificialmente anios_esc y deprimen exper (de ahí el mínimo de -76). La regresión de arriba los **incluye**, tal como pediste la especificación.

Código

```
# Construcción de variables
muestra['exper'] = muestra['eda'] - muestra['anios_esc'] - 6
```

```
muestra['mujer'] = (muestra['sex'] == 2).astype(int) # Estimación
vars_x = ['años_esc', 'exper', 'mujer', 'hrsocup']
datos_m2 = muestra[['ing_x_hrs'] + vars_x].dropna()
modelo2 = sm.OLS(datos_m2['ing_x_hrs'], sm.add_constant(datos_m2[vars_x])).fit()
```

Mi recomendación: reestimar excluyendo `anios_esc == 99` y `exper < 0` (unos 48 casos, ~1.3% de la muestra) para ver qué tanto mueven los coeficientes. ¿Lo corro como versión “limpia” para comparar?

Turn 6

User

Si, corre la version limpia, pero solo como comparacion: la regresion oficial sigue siendo la de la muestra completa. Muestrame una tabla lado a lado (coeficiente con muestra completa vs limpia y el cambio porcentual de cada uno), cuantas observaciones quedaron, y la R-cuadrada de ambas. Guarda todo en el notebook sin borrar lo anterior.

Assistant

Thinking

Add cells: clean version excluding anios esc==99 and exper<0, side-by-side table with % change, n, R² both. Keep everything.

Agrego la comparación limpia vs. completa al notebook.

Tool Call: Write (/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase...

```
{
    "content": "import nbformat\n\nruta = \"/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/Modelos_ENOE_NL.ipynb"\n\nnbformat.read(ruta, as_version=4)\n\nnb.cells.append(nbformat.v4.new_markdown_cell(\n    "\n\n## Regresión 2b:\nversión limpia (solo comparación)\n\nLa regresión **oficial** es la de la muestra completa (Regresión 2).\n\nAquí se reestima excluyendo `anios_esc == 99` y `exper < 0`,\n\núnicamente para comparar coeficientes.\n\n"))\n\nnb.cells.append(nbformat.v4.new_code_cell(\n    "\n# --- Muestra limpia: excluir códigos inválidos ---\n\nlimpia = (muestra['anios_esc'] != 99) & (muestra['exper'] >= 0)\n\ndatos_m2b = muestra.loc[limpia, ['ing_x_hrs'] + vars_x].dropna()\n\nprint(f'Excluidas: {(~limpia).sum()} observaciones')\n\nf'(anios_esc==99: {(muestra[['anios_esc']] == 99).sum()}, '\n\nf'exper<0 con anios_esc!=99: (((muestra[['exper']] < 0) & (muestra[['anios_esc']] != 99)).sum()))'\n\nprint(f'Observaciones en versión limpia: {len(datos_m2b),})'\n\n\nmodelo2b = sm.OLS(datos_m2b['ing_x_hrs'], sm.add_constant(datos_m2b[vars_x])).fit()\n\n\n# --- Tabla lado a lado ---\n\ncomp = pd.DataFrame({'Completa (oficial)': modelo2.params,\n\n    'EE completa': modelo2.bse,\n\n    'Limpia': modelo2b.params,\n\n    'EE limpia': modelo2b.bse,\n\n    'Cambio % coef.' = (comp['Completa (oficial)' - 1] * 100)\n\ncomp.round(4)\n\nprint(f'R^2 completa (oficial): {modelo2.rsquared:.4f} | R^2 limpia: {modelo2b.rsquared:.4f}')\n\nprint(f'n completa: {int(modelo2.nobs):}, n limpia: {int(modelo2b.nobs):}, '\n\ncomp\n\n))\n\nnbformat.write(nb, ruta)\n\nprint("Celdas agregadas")\n\n",
    "path": "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/agregar_reg2b.py"
```

Tool Result: Write (/Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase...

Wrote 1926 bytes to /Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/agregar_reg2b.py

Tool Call: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

```
{
  "command": "cd \"C:/Users/gabrielomarperzhernandez/Desktop/Carpeta Local Clase\" &&
```

```
.venv/bin/python agregar_reg2b.py && .venv/bin/python ejecutar_nb.py 2>/dev/null &&
.venv/bin/python - <<'EOF'\nimport nbformat\nnb = nbformat.read(\"Modelos_ENOE_NL.ipynb\",
as_version=4)\nncel = nb.cells[-1]\nfor sal in cel.get(\"outputs\", []):\n    if
sal.output_type == \"stream\":\n        print(sal.text)\n    elif sal.output_type ==
\"execute_result\":\n        print(sal.get(\"data\", {})).get(\"text/plain\", \"\")\n    elif
sal.output_type == \"error\":\n        print(\"ERROR:\", sal.ename, sal.evalue)\nEOF\",
\"timeout\": 300}
```

Tool Result: Bash (cd "/Users/gabrielomarperezhernandez/Desktop/Carpeta Local C...)

Celdas agregadas Notebook ejecutado y guardado: /Users/gabrielomarperezhernandez/Desktop/Carpeta Local Clase/Modelos_ENOE_NL.ipynb Excluidas: 36 observaciones (anios_esc==99: 12, exper<0 con anios_esc!=99: 24) Observaciones en versión limpia: 3,546

R² completa (oficial): 0.1071 | R² limpia: 0.1504 n completa: 3,582 | n limpia: 3,546

Completa (oficial)	EE completa	p completa	Limpia	EE limpia	\
--------------------	-------------	------------	--------	-----------	---

const	142.4843	7.0361	0.0000	86.0650	8.2218
anios_esc	2.3997	0.2831	0.0000	7.2374	0.4603
exper	0.2434	0.1114	0.0289	0.5334	0.1124
mujer	-20.9263	3.2001	0.0000	-23.6679	3.1559
hrsocup	-1.8295	0.0990	0.0000	-1.8290	0.0975

p limpia	Cambio % coef.
----------	----------------

const	0.0	-39.5969
anios_esc	0.0	201.5990
exper	0.0	119.1027
mujer	0.0	13.1008
hrsocup	0.0	-0.0271

Thinking

Report side-by-side. Notably only 36 excluded (12 of the 36 exper<0 overlap with anios_esc==99). The anios_esc coefficient triples in clean version — big finding. R² rises to 0.150. All still significant.

Comparación lista y guardada en el notebook. **La regresión oficial sigue siendo la de muestra completa**; esto es solo diagnóstico.

Muestra limpia

Se excluyeron **36 observaciones** (12 con anios_esc == 99 + 24 con exper < 0; los 12 de escolaridad 99 también caían en experiencia negativa). Quedan **3,546** observaciones (vs. 3,582 en la completa).

Tabla lado a lado

Variable	Completa (oficial)	Limpia	Cambio % del coef.
Intercepto	142.48	86.07	-39.6%
anios_esc	2.40	7.24	+201.6%
exper	0.24	0.53	+119.1%
mujer	-20.93	-23.67	+13.1%
hrsocup	-1.83	-1.83	-0.03%

Todas las variables siguen siendo significativas al 1% en ambas versiones (p < 0.001; solo exper tenía p = 0.029 en la completa y pasa a p < 0.001 en la limpia).

R² completa (oficial) = 0.1071 | R² limpia = 0.1504

Los 36 casos raros distorsionaban fuerte los coeficientes de `anios_esc` y `exper`: el retorno a la escolaridad pasa de \$2.40 a **\$7.24 pesos/hora por año** al quitarlos — los `anios_esc == 99` actuaban como outliers de alto apalancamiento. `hrsocup` es inmune; la brecha de género se amplía un poco ($-\$20.93 \rightarrow -\23.67).

```
limpia = (muestra['anios_esc'] != 99) & (muestra['exper'] >= 0)
datos_m2b = muestra.loc[limpia, ['ing_x_hrs'] + vars_x].dropna()
modelo2b = sm.OLS(datos_m2b['ing_x_hrs'], sm.add_constant(datos_m2b[vars_x])).fit()

comp = pd.DataFrame({
    'Completa (oficial)': modelo2.params, 'EE completa': modelo2.bse, 'p completa':
    modelo2.pvalues,
    'Limpia': modelo2b.params, 'EE limpia': modelo2b.bse, 'p limpia': modelo2b.pvalues,
})
comp['Cambio % coef.'] = (comp['Limpia'] / comp['Completa (oficial)'] - 1) * 100
```

Turn 7

Ahora comparemos los dos modelos oficiales: `anios_esc` dio 1.98 en la regresion simple y 2.40 en la multiple. Para explicar por que subio, calculame (1) la correlacion entre `anios_esc` y `exper` en la muestra completa, (2) una regresion auxiliar de `exper` sobre `anios_esc`, y (3) verifica la formula del sesgo de variable omitida: $\text{coef_simple} = \text{coef_multiple} + (\text{coef de } \text{exper}) \times (\text{pendiente auxiliar})$. Todo con el codigo, como siempre.

Thinking

Compute correlation, auxiliary regression $\text{exper} \sim \text{anios_esc}$, verify omitted variable bias identity: $\beta_{\text{simple}} = \beta_{\text{multi}} + \beta_{\text{exper}} * \delta$ where δ from $\text{exper} = \delta_0 + \delta_1 \text{anios_esc}$. Full sample (official). Add to notebook.

Tool Call: Write (/Users/gabrielomarperzhernandez/Desktop/Carpeta Local Clase...)

14

Corte p99
 de
 ing_x_hrs:
 \$408.82/hr
 Excluidas:
 36 obs |
 quedan:
 3,546

 R² oficial:
 0.1071 |
 R² sin top
 1%:
 0.1539

 Oficial
 (completa)
 Sin top
 1% EE sin
 top 1% p
 sin top 1%
 const
 142.4843
 114.3767
 4.3266
 0.0000
 anios_esc
 2.3997
 2.2151
 0.1729
 0.0000
 exper
 0.2434
 0.2313
 0.0681
 0.0007
 mujer
 -20.9263
 -15.2353
 1.9587
 0.0000
 hrsocup
 -1.8295
 -1.3006
 0.0611
 0.0000

 Cambio %
 coef. const
 -19.7269
 anios_esc
 -7.6917
 exper
 -4.9886
 mujer
 -27.1955
 hrsocup
 -28.9105

Desv. est. global de residuales: 91.75

```

n desv_est varianza desv_est / global
anios_esc
0-9 años 1701 98.99 9799.96 1.079 10-12 años 1060 62.10 3856.51 0.677 13+ años 821 102.89 10585.83 1.121 — anios_esc exper mujer
hrsocup anios_esc 1.000 -0.513 0.021 0.015 exper -0.513 1.000 -0.021 -0.069 mujer 0.021 -0.021 1.000 -0.203 hrsocup 0.015 -0.069 -0.203
1.000

```

Thinking

Report results and rank the three problems. Residual variance is clearly non-constant (62 vs 99-103), heteroscedasticity. Outliers move coefficients notably (up to -29% for hrsocup, -27% mujer). Multicollinearity is mild except anios_esc-exper (-0.513, mechanical). Ranking: I'd say heteroscedasticity affects inference (SEs wrong) but coefficients unbiased; outliers move point estimates substantially — for confiability of the model, outliers probably most grave since they shift estimates; heteroscedasticity second (inference invalid); multicollinearity least (only one pair, -0.51, mechanical, VIF modest). That's a defensible ranking. Present with code.

Diagnósticos corridos y guardados en el notebook. Resultados:

(1) Outliers — reestimación sin el 1% más alto de ing_x_hrs

Corte en p99 = **\$408.82/hr**; se excluyeron 36 obs, quedan 3,546. R² sube de 0.107 a 0.154.

Variable	Oficial	Sin top 1%	Cambio %
Intercepto	142.48	114.38	-19.7%
anios_esc	2.40	2.22	-7.7%
exper	0.24	0.23	-5.0%
mujer	-20.93	-15.24	-27.2%
hrsocup	-1.83	-1.30	-28.9%

Todas siguen significativas ($p \leq 0.001$), pero los coeficientes de mujer y hrsocup se reducen casi una tercera parte: el top 1% de ingresos está inflando esos efectos.

(2) Varianza del error por escolaridad

Desv. est. global de residuales: 91.75.

Grupo	n	Desv. est. residuales	vs. global
0-9 años	1,701	98.99	1.08×
10-12 años	1,060	62.10	0.68×
13+ años	821	102.89	1.12×

No es constante: el grupo de 10-12 años tiene una dispersión ~40% menor que los extremos (forma de U). Hay heteroscedasticidad clara, lo que invalida los errores estándar clásicos reportados (los coeficientes siguen insesgados, pero la inferencia requiere EE robustos).

(3) Matriz de correlación entre regresores

	anios_esc	exper	mujer	hrsocup
anios_esc	1.000	-0.513	0.021	0.015
exper	-0.513	1.000	-0.021	-0.069
mujer	0.021	-0.021	1.000	-0.203
hrsocup	0.015	-0.069	-0.203	1.000

La única correlación relevante es anios_esc ↔ exper (-0.51), y es casi mecánica por construcción ($\text{exper} = \text{eda} - \text{anios_esc} - 6$). No hay multicolinealidad preocupante.

Ranking de gravedad para la confiabilidad del modelo

1. **Outliers de ingreso (más grave)** — 36 observaciones mueven los coeficientes hasta 29%: afectan directamente las *estimaciones puntuales*, que es lo que interpretas. Sumado a lo que ya vimos con `anios_esc == 99`, el modelo oficial es frágil ante casos extremos.
2. **Heteroscedasticidad** — no sesga los coeficientes, pero los errores estándar y p-values reportados no son confiables; se corrige fácil con `fit(cov_type='HC1')`.
3. **Correlación entre regresores (menos grave)** — solo un par con $|r| \approx 0.5$ y de origen mecánico; los EE no están inflados de forma problemática y los coeficientes son estables.

Código

```
# (1) Outliers
p99 = datos_m2['ing_x_hrs'].quantile(0.99)
recortada = datos_m2[datos_m2['ing_x_hrs'] <= p99]
modelo2c = sm.OLS(recortada['ing_x_hrs'], sm.add_constant(recortada[vars_x])).fit()

# (2) Varianza del error por grupo
res = modelo2.resid
grupo = pd.cut(datos_m2['anios_esc'], bins=[-1, 9, 12, np.inf],
               labels=['0-9 años', '10-12 años', '13+ años'])
var_error = res.groupby(grupo, observed=True).agg(n='count', desv_est='std', varianza='var')

# (3) Correlaciones
matriz_corr = datos_m2[vars_x].corr()
```

Con esto quedan los tres análisis en `Modelos_ENOE_NL.ipynb`. Si quieres, como cierre natural puedo agregar la versión del modelo oficial con errores robustos HC1 para dejar la inferencia bien sustentada.